



UNIVERSIDAD DE LOS LAGOS

Síntesis de Aprendizaje: De la Teoría a la Realidad

Explorando modelos, Datos y Diagnósticos

**DATA.
MINING.**

Taxonomía de la Minería de Datos



Modelos Predictivos

Aprendizaje supervisado.
Orientado a un objetivo
(Variable Dependiente).

Regresión
(Valores numéricos)

Clasificación
(Categorías discretas)



Modelos Descriptivos

Aprendizaje no supervisado.
Orientado a descubrir estructuras
ocultas y relaciones indirectas.

Agrupamiento
(Clustering)


Reglas de
Asociación

El Motor Predictivo: Entrenamiento y Predicción




Modelos Descriptivos: Exploración sin Etiquetas

Agrupamiento (Clustering)




Une observaciones empíricas basadas en similitudes inherentes. No existen categorías previas; los datos revelan su propia estructura.

Descubrimiento de Patrones



Identifica asociaciones transaccionales. Mide la frecuencia (Soporte) y la probabilidad condicional (Confianza) de que eventos ocurran juntos.


El Escenario: Dataset de Seguros Médicos (Insurance)




Expenses (Gastos)

Variable Objetivo.
El costo médico continuo a predecir.

Análisis Exploratorio (EDA): Escuchando a los Datos



Fuerte correlación bivariada. La edad y el IMC tienen un impacto directo en los gastos.



El Factor Crítico


Ser fumador altera drásticamente la estructura de costos, especialmente cuando interactúa con un IMC elevado.

Advertencia de Multicolinealidad: Las variables no operan en el vacío.

Anatomía del Modelo: Regresión Lineal



UNIVERSIDAD DE LOS LAGOS



Resultados: El Panel de Control del Modelo



Coeficiente de Determinación (R^2)

0.8760

Explica el 87.6% de la variabilidad.
Un resultado aparentemente sólido
para un modelo inicial.



Error Absoluto Medio (MAE)

2,892.29

Desviación promedio esperada en
unidades monetarias.




Error Cuadrático Medio (RMSE)

4,409.65

Significativamente mayor que el
MAE. Revela la existencia de errores
catastróficos puntuales.

Análisis de Residuos: La Realidad es Desordenada



El Sesgo de Subestimación.
El modelo asume una pendiente única, pero la variable 'Smoker' crea una población paralela. El modelo lineal simple es ineficaz y peligroso para predecir casos de alto costo.

El gráfico revela heterocedasticidad. La dispersión de los errores no es aleatoria; varía violentamente en los niveles altos de gasto.

Conclusión: El Verdadero Rol del Analista



Un modelo no es un número único.
Es un diagnóstico tridimensional de la realidad frente a la predicción.

Las métricas (R^2) validan el patrón, pero el análisis de residuos revela los puntos ciegos. La minería de datos requiere contexto, escepticismo y comprensión del negocio, no solo ejecución algorítmica.