




UNIVERSIDAD DE LOS LAGOS

TÉCNICAS DE EVALUACIÓN EN MINERÍA DE DATOS

COMO MEDIR LA VERDADERA INTELIGENCIA DEL NEGOCIO




El modelo aprende, pero ¿podemos confiar en él?



Construir un modelo es solo el primer paso.
Si un error de predicción tiene consecuencias graves (ej. detección de células cancerígenas), necesitamos medir su precisión real antes de aplicarlo.

Evaluar un modelo de forma equivocada es más peligroso que no tener un modelo.

La trampa de la «memoria»



Si evaluamos un modelo con los mismos datos que usó para entrenar, no estamos midiendo su capacidad de aprender, sino su capacidad de memorizar.


Este error premia a los modelos que se ajustan perfectamente a los datos conocidos, pero que fracasarán estrepitosamente ante datos nuevos.

El Espectro del Aprendizaje: Encontrando el Equilibrio

Subajuste (Underfitting)

Entrenamiento: Malos resultados. El modelo es perezoso o tiene pocos datos.


Prueba: Malos resultados. No capta los patrones.



Óptimo (Equilibrio)

Entrenamiento: Buenos resultados.


Prueba: Buenos resultados. Generaliza correctamente.




Sobreajuste (Overfitting)

Entrenamiento: Resultados «perfectos» (memoriza el ruido).


Prueba: Falla al recibir datos no vistos.



El «Punto Dulce» de la Complejidad




La Solución Fundamental: Ocultar Datos



Para evitar el sobreajuste, dividimos la evidencia. El modelo solo verá la parte azul para aprender. La parte naranja se mantiene en secreto hasta el examen final.

Fase 1: El Proceso de Aprendizaje



Datos de Entrenamiento



Ajuste de Parámetros


El modelo itera, buscando patrones y minimizando el error con las respuestas conocidas.

(Técnicamente: Minimización de la diferencia entre predicción y realidad)




Modelo Entrenado

Fase 2: El Proceso de Evaluación



**Datos de Prueba
(No Vistos)**



Simulación Real

Alimentamos al modelo entrenado con los datos secretos.




Evaluación de Precisión

Comparamos las predicciones del modelo con las etiquetas reales.

Si el modelo acierta un 90% en entrenamiento pero falla catastróficamente aquí... hemos detectado Overfitting.

¿Y si tenemos muy pocos datos?



La **división 80/20 tradicional** funciona bien con **grandes volúmenes de datos**. Pero si el conjunto es pequeño, separar un 20% podría privar al modelo de información vital para aprender.

Necesitamos una evaluación más robusta que aproveche el 100% de los datos
tanto para entrenar como para **evaluar**.

Entra la Validación Cruzada (Cross-Validation)

Método k-fold: Aprovechando cada dato

The K-Fold Escalator



1. Dividir datos en **k** partes (ej. $k=5$).
2. Entrenar con **k-1** partes, evaluar con la parte restante.
3. Repetir **k** veces, rotando la parte de evaluación.
4. Promediar los resultados para la métrica final.


Síntesis: La Evolución de la Robustez



El Error Principal: Entrenar y evaluar con los mismos datos (Peligro de Sobreajuste).



La Solución Básica: Segmentación clásica (Train/Test Split).



La Evaluación Avanzada: Validación Cruzada (Mayor robustez para datos limitados).

Un buen modelo de minería de datos no es el que memoriza el pasado, sino el que predice con precisión el futuro.