

Evaluación Sumativa n°2

Sistema de Tasación Inteligente "InnovaReal Estate"

1. Introducción y Objetivo

Usted ha sido contratado como Data Scientist por la corredora *InnovaReal Estate*. El mercado inmobiliario se encuentra muy volátil y las tasaciones manuales están fallando. Su misión es construir un modelo predictivo utilizando el dataset `house-prices.csv` para estandarizar los precios de venta. **Entregable:** Un Jupyter Notebook (.ipynb) que contenga el código, las visualizaciones y un análisis crítico profundo en celdas de texto (markdown) del mismo documento. Se adicionará puntaje a los estudiantes que comenten detalladamente el código, conservando un uso correcto de la ortografía.

2. Paso a Paso del Proyecto (Metodología)

Fase I: Comprensión y Preparación de Datos

1. **Limpieza:** Cargue los datos y elimine la columna `Home`. Justifique por qué los identificadores no deben entrar al modelo.
2. **Verificación de Nulos:** Aunque el dataset parezca limpio, debe incluir el código de validación.
3. **Exploración Visual (EDA):**
 - ☐ Cree un **Heatmap** de correlación. Identifique las 3 variables con mayor impacto en el precio de las propiedades.
 - ☐ Cree un **Boxplot** de `Price` segmentado por `Neighborhood`. ¿En qué barrio se encuentran las casas más costosas?
 - ☐ Cree un **Scatter Plot** de `SqFt` vs `Price` diferenciando por `Brick (Material)`.

Fase II: Ingeniería de Datos

1. **Encoding:** Aplique *One-Hot Encoding* a las variables categóricas. Explique el concepto de "Variable Ficticia" y justifique por qué usamos `drop_first=True`.
2. **División:** Use un 80% de los datos para entrenar y un 20% para testear (`random_state=42`).
3. **Escalado:** Aplique `StandardScaler`. Explique por qué es necesario igualar las magnitudes de `SqFt` y `Bedrooms`.



Fase III: Modelado y Evaluación

1. **Regresión:** Entrene una Regresión Lineal Múltiple.
2. **Métricas:** Calcule el R^2 , MAE y RMSE.
3. **Visualización de Errores:** Grafique **Predicciones vs. Valores Reales**.
 - ☐ Grafique los **Residuos** mediante un diagrama de dispersión.

3. Preguntas de Análisis Crítico

Como analista, debes responder estas 5 preguntas de manera clara:

1. **Interpretación:** Si una casa suma un dormitorio adicional, pero mantiene los mismos metros cuadrados, ¿el precio sube o baja según sus coeficientes? Explique la lógica.
2. **Impacto del Barrio:** ¿Cuál es la "prima" o valor extra en dólares que el mercado paga solo por estar en el barrio **West** frente al barrio **East**?
3. **Análisis de Ofertas:** La variable Offers suele tener coeficiente negativo. ¿Significa esto que recibir ofertas quita valor a la casa? Proponga una explicación de negocio.
4. **Diagnóstico de Gráficos:** En su gráfica de Residuos, ¿los errores se distribuyen de forma aleatoria o hay algún patrón? ¿Qué significa esto para la fiabilidad del modelo?
5. **Recomendación:** Si la inmobiliaria quiere captar casas nuevas, ¿qué perfil de casa (Barrio/Material/SqFt) le recomendaría buscar para asegurar el precio de venta más alto?



4. Configuración tipo:

```
#Declaración de librerías
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error
```

```
#Ingesta de datos
df = pd.read_csv('house-prices.csv').drop('Home', axis=1)
```

```
#Exploración de los datos
plt.figure(figsize=(10,4))
sns.heatmap(df.corr(numeric_only=True), annot=True, cmap='magma')
plt.title("¿Qué variables 'están más correlacionadas'?")
plt.show()
```

```
#Aplicación de One-Hot Encoding y Escalado.
df_prep = pd.get_dummies(df, columns=['Brick', 'Neighborhood'], drop_first=True)

X = df_prep.drop('Price', axis=1)
y = df_prep['Price']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

```
#Modelado y evaluación
model = LinearRegression()
model.fit(X_train_scaled, y_train)
y_pred = model.predict(X_test_scaled)
```

```
#Análisis de impacto sobre el negocio
coef_df = pd.DataFrame({
    'Variable': X.columns,
    'Impacto_USD': model.coef_
}).sort_values(by='Impacto_USD', ascending=False)

print("RANKING DE VALORIZACIÓN:")
print(coef_df)
```