

TAREA SUMATIVA

Selección Libre y Pre procesamiento de Datos	
Asignatura: Plataforma de Entrega:	Aula Virtual
Modalidad de Trabajo:	Grupal (Parejas) o Individual
Formato de Entrega:	Archivo en python (.ipynb)
Ponderación:	15% de la nota final del módulo
Plazo de entrega:	11 de Junio del 2026 23:59 hrs.

1. Material de Apoyo Obligatorio

Para la correcta ejecución de este desafío, los estudiantes deberán repasar de forma obligatoria los conceptos, contenidos y trabajos prácticos vistos hasta la fecha y que se encuentran debidamente cargado en la plataforma Aula Virtual.

2. Antecedentes y Contexto del Desafío

Actualmente, los analistas rara vez se encuentran con conjuntos de datos perfectos. La captura de datos suele verse afectada por procesos imperfectos que introducen registros corruptos, irrelevantes, nulos o con variaciones extremas. La limpieza de datos (Data Cleansing) es fundamental, ya que operar con datos de baja calidad distorsiona los análisis y genera consecuencias graves en la toma de decisiones estratégicas.

En esta actividad, usted asumirá el rol de un científico de datos y tendrá la libertad de explorar y seleccionar un caso de estudio real directamente desde la plataforma Kaggle para demostrar sus habilidades de preprocesamiento.

3. Instrucciones Específicas de la Actividad

El notebook entregado a través del Aula Virtual debe estar estructurado bajo las siguientes fases de desarrollo:

- **Fase 1: Selección del Dataset y Justificación (Kaggle)**

- a) Ingresar a la plataforma de datos abiertos a través del enlace: <https://www.kaggle.com/datasets>
- b) Buscar y descargar de manera autónoma un set de datos de su interés.
- c) El dataset elegido debe cumplir obligatoriamente con tres condiciones técnicas:
 - Contener una mezcla de columnas de datos categóricos y cuantitativos (numéricos).
 - Presentar de forma comprobable la existencia de datos nulos o valores faltantes.
 - Evidenciar la presencia de potenciales valores atípicos (outliers) en sus variables cuantitativas.

- d) En la primera celda de texto del Notebook, redactar brevemente el contexto del negocio del dataset elegido y justificar por qué cumple con los requisitos mínimos de la actividad.

- **Fase 2: Carga, Estructura y Diagnóstico Inicial**

- a) Realizar la carga del archivo .csv original mediante la librería pandas.
- b) Utilizar funciones de diagnóstico para conocer la cantidad total de observaciones (filas) y características (columnas).
- c) Clasificar y agrupar las columnas según su tipo de datos (conocer cuántas categóricas y cuántas numéricas posee el set).
- d) Desplegar un informe claro que muestre el volumen y el porcentaje exacto de valores nulos presentes en cada una de las variables.

- **Fase 3: Tratamiento de Valores Faltantes (Missing Values)**

Basándose en el material teórico visto en clases, apliquen de manera justificada las siguientes estrategias de remediación:

- a) **Evaluación de Descarte:** Determinar si es viable aplicar la eliminación por lista o por pares en alguna columna, fundamentando si el porcentaje de pérdida compromete o no la integridad del dataset.
- b) **Imputación Simple:** Aplicar imputación de valores nulos con la media o la mediana para variables numéricas u otra técnica. Deben justificar su elección explicando si la alternativa elegida altera o preserva la distribución original de los datos.
- c) **Imputación Avanzada / Categórica:** Para las variables de tipo categórico, aplicar la sustitución utilizando la moda o codificando una constante que identifique explícitamente el registro como faltante. Si lo consideran pertinente por la complejidad del dataset, exploren métodos de imputación hot-deck o alguna otra técnica investigada por cuenta propia.

- **Fase 4: Detección y Tratamiento de Valores Atípicos (Outliers)**

- a) **Visualización:** Diseñar gráficos de caja (boxplot) o de dispersión (scatter plot) empleando matplotlib o seaborn para evidenciar los outliers univariados o multivariados de las columnas numéricas principales.
- b) **Criterio Métrico:** Aplicar formalmente el método estadístico del **Rango Intercuartílico (IQR)** para establecer los límites e identificar con precisión matemática qué registros califican como valores atípicos.
- c) **Acción de Limpieza:** Ejecutar una estrategia de tratamiento para estos outliers. Puede optar por filtrarlos (eliminarlos) o imputarlos por la mediana o media de la muestra. Explique detalladamente el criterio analítico detrás de su decisión.

Fase 5: Transformación Final y Exportación

- Aplicar técnicas de transformación básica (como codificación o encoding) en al menos una variable categórica relevante para que quede expresada en formato numérico.
- Guardar y exportar el proyecto (archivo en python+dataset) y subirlo al Aula Virtual con el nombre y apellido de el o los integrantes.

4. Rúbrica de Evaluación (Escala del 1.0 al 7.0)

Criterio de Evaluación	Logrado	Medianamente Logrado	No Logrado
Selección y Justificación del Dataset (15%)	El dataset proviene de la URL solicitada, posee un contexto claro y cumple explícitamente con los tres requisitos (nulos, outliers y tipos mixtos).	El dataset cumple parcialmente con los requisitos técnicos o la descripción del contexto de negocio es muy vaga.	El dataset no cumple con las condiciones mínimas exigidas o no proviene de la fuente indicada.
Diagnóstico y Análisis de Estructura (15%)	Muestra con total exactitud la cantidad de filas/columnas, la tipología de datos y calcula de forma porcentual los nulos por variable.	Reporta la presencia de datos nulos, pero carece de un análisis estructurado o no detalla la proporción porcentual de los mismos.	Falla al cargar el archivo o no realiza el análisis de diagnóstico inicial sobre la calidad de los datos.
Tratamiento Técnico de Nulos (25%)	Implementa de forma limpia estrategias de descarte o imputación (media, mediana o moda), justificando matemáticamente que no se alteró la distribución.	Aplica imputaciones básicas para rellenar los vacíos, pero no fundamenta técnicamente el uso de un estimador sobre otro.	No resuelve los valores faltantes o la técnica aplicada corrompe la coherencia lógica de las variables.
Identificación y Corrección de Outliers (25%)	Detecta outliers combinando gráficos (boxplot) y métricas analíticas (IQR), aplicando un filtro o imputación bien fundamentado.	Identifica la existencia de outliers de manera visual, pero comete errores en el cálculo de los límites matemáticos del IQR.	No implementa métodos de detección visual ni métrica, o ignora el impacto de los valores atípicos.
Transformación, Código y Calidad (20%)	Realiza codificación de variables categóricas, exporta de forma exitosa el archivo final y entrega el notebook limpio y documentado con comentarios estructurados.	Exporta el archivo final modificado, pero el código es desordenado, carece de explicaciones o no realiza la transformación de variables nominales.	El notebook presenta errores de sintaxis que impiden su ejecución o no genera el archivo final procesado.